Auditoría de costes y escalado · Cartagenaeste

Fecha: 2026-04-24

Autor: Carlos Galera Román

Propósito: inventario completo de costes actuales, proyección a 1.000 usuarios activos mensuales (MAU) y necesidades técnicas para sostener ese volumen con SLA 99,5% · p95 <5s.

> Este documento se mantiene al día después de cada cambio de arquitectura o precio de proveedor. Usarlo como anexo económico en el dossier comercial y en la propuesta AstraZeneca.

0. TL;DR

ESCENARIO	MAU	COSTE MENSUAL EUR	COSTE ANUAL EUR
Hoy (uso real, fase temprana)	<20	**≈ 0 €** (tier gratuito)	≈ 0 €
100 MAU (Urgencias HSL firmado)	100	**35 - 85 €/mes**	420 - 1.020 €/año
1.000 MAU (SMS multi-servicio)	1.000	**180 - 420 €/mes**	2.160 - 5.040 €/año
Escenario pesimista 1.000 MAU · uso intensivo IA	1.000	**380 - 650 €/mes**	4.560 - 7.800 €/año

Lectura comercial: la factura de 14.000 €/año a HSL (dossier comercial) cubre costes de infraestructura con **margen amplio** incluso en escenario pesimista de 1.000 MAU, con lo que los servicios de desarrollo, soporte y formación quedan íntegramente como valor añadido.

1. Stack actual · inventario de componentes

COMPONENTE	PROVEEDOR	ESTADO FACTURACIÓN	PLAN	REGIÓN
Dominio `area2cartagena.es`	Registrador externo	Autofinanciado	12-15 €/año	N/A
Hosting frontend	GitHub Pages	Gratis (cuenta personal)	—	Global CDN
Firestore (database)	Firebase / Google Cloud	**No facturado** (free tier)	Spark → Blaze pending	europe-west1
Firebase Auth	Firebase	Gratis	Spark	europe-west1
Firebase Storage	Firebase	Gratis	Spark	europe-west1
Cloud Functions (6 desplegadas)	Firebase	Gratis (<2M invoc/mes)	Spark	europe-west1
App Check	Firebase	Gratis	Spark	N/A
Backups diarios Firestore	Google Cloud Storage	**No activo** (requiere Blaze)	—	europe-west1
DeepSeek API	DeepSeek	**No facturado** (tier free)	Free	CN
OpenRouter API	OpenRouter	**No facturado** (saldo testing)	Pay-as-you-go	US/UE variable
Qwen / Gemini / Mistral direct	Varios	No usado por defecto	Opcional	Variable
Sentry	Sentry.io	Gratis (dev team)	Team free	EU
Google Analytics 4	Google	Gratis	Standard	UE
Uptime Robot (pendiente activar)	Uptime Robot	Gratis	Free 50 monitors	N/A
Email / push	No activos	—	—	—

Total facturado hoy: ~15 €/año (solo dominio).

Cloud Functions desplegadas (europe-west1)

FUNCIÓN	TIPO	CRON / TRIGGER	MEMORIA	TIEMPO EJECUCIÓN TÍPICO
`askAi`	onCall	user	512 MiB	2-30 s
`publicMetrics`	HTTP GET	user	256 MiB	<1 s
`setUserRole`	onCall	admin	256 MiB	<1 s
`auditCases`, `auditAiRequests`, `auditSugerencias`, `auditDocumentosAprobados`, `auditTriajes`, `auditInformesIa`, `auditScanUploads`	triggers Firestore	writes	256 MiB	<500 ms
`weeklyMetricsSnapshot`	scheduler	lun 03:00	512 MiB	10-30 s
`dailyBackup`	scheduler	diario 03:00	256 MiB	30-120 s
`weeklyAuditDigest`	scheduler	lun 09:00	256 MiB	5-15 s
`aggregateDailyMetrics`	scheduler	diario 02:30	512 MiB	5-20 s
`healthCheckAi`	scheduler	diario 06:00	256 MiB	10-30 s
`goldStandardEval`	scheduler	mensual día 1 04:00	1 GiB	30-120 s
`fhirExport`	onCall	user admin	512 MiB	1-5 s

---

2. Tarifas actuales de referencia (2026)

2.1 Firebase / GCP · europe-west1

RECURSO	UMBRAL GRATUITO MENSUAL	PRECIO TRAS UMBRAL
Firestore lecturas	50.000 / día	0,06 $/100k
Firestore escrituras	20.000 / día	0,18 $/100k
Firestore eliminaciones	20.000 / día	0,02 $/100k
Firestore storage	1 GiB	0,18 $/GiB/mes
Cloud Functions invocaciones	2.000.000 / mes	0,40 $/M
Cloud Functions GB-s	400.000	0,0000025 $/GB-s
Cloud Functions CPU-s	200.000	0,0000100 $/CPU-s
Firebase Auth MAU	50.000	0,0055 $/MAU (UE)
Storage	5 GiB	0,026 $/GiB/mes (standard)
Egress	1 GiB	0,12 $/GiB (internet)

2.2 Proveedores IA · por 1M tokens (promedio)

PROVEEDOR · MODELO	INPUT	OUTPUT	NOTA
DeepSeek V3	0,27 $	1,10 $	Tier free con rate limit severo
DeepSeek V3 (paid)	0,27 $	1,10 $	Sin rate limit clínico
Gemini 2.5 Flash-Lite	0,10 $	0,40 $	UE directo
Gemini 2.5 Flash	0,30 $	2,50 $	UE directo · vision
Mistral Small 3.2	0,20 $	0,60 $	UE directo
Qwen 2.5-VL-72B (DashScope)	1,80 $	5,40 $	Intl routing
OpenRouter (routing)	+10-25% markup sobre el modelo		
Anthropic Claude Haiku 4.5	1,00 $	5,00 $	UE disponible · pago facturable

3. Proyección por escenario

3.1 Asunciones del modelo de uso

MÉTRICA	HOY	100 MAU	1.000 MAU
MAU	15	100	1.000
DAU aprox (20% MAU)	3	20	200
Peticiones IA / usuario / día	3	5	6
Peticiones IA totales / mes	200	3.000	36.000
Tokens promedio por llamada (in/out)	600 / 500	800 / 700	1.000 / 900
Imágenes analizadas / día	0-2	5-10	30-80
Sesiones con datos	300/mes	2.500/mes	24.000/mes
Reads Firestore / mes	8.000	80.000	800.000
Writes Firestore / mes	2.000	18.000	200.000
Storage Firestore	<100 MiB	500 MiB	3-5 GiB
Tráfico egress / mes	<200 MiB	2 GiB	20 GiB

3.2 Escenario HOY

Todo dentro de tier gratuito salvo dominio.

- Dominio: 1,25 €/mes
- Firebase: 0 €/mes (ampliamente bajo umbral)
- DeepSeek free + OpenRouter testing: 0 €/mes
- **TOTAL: ≈ 1,25 €/mes · 15 €/año**

3.3 Escenario 100 MAU (Urgencias HSL firmado · 2026-Q3)

- Dominio: 1,25 €/mes
- Firebase (estimado activando Blaze):
- Reads 80k → dentro free tier
- Writes 18k → dentro free tier
- Functions 500k invocaciones → dentro free tier
- Auth 100 MAU → 0,55 €/mes
- Storage 500 MiB → 0,09 €/mes
- Egress 2 GiB → 0,22 €/mes
- Backups (GCS) 50 MiB/día · 30d = 1,5 GiB → 0,04 €/mes
- **Subtotal Firebase: ≈ 1 €/mes**
- IA (con SLA pagado):
- Escenario **híbrido económico** (90% DeepSeek paid, 10% Gemini Flash):
- 3.000 llamadas · 1.500 tokens promedio · 0,70 $/1M = **3 $/mes**
- Con markup OpenRouter +15% = **3,5 $/mes ≈ 3,30 €/mes**
- Escenario **premium** (50% Gemini Flash-Lite, 30% Gemini Flash, 20% Qwen VL):
- 3.000 llamadas · mix = **25 $/mes ≈ 23 €/mes**
- Escenario **Anthropic como primario** (Claude Haiku para clinical_case):
- 3.000 llamadas · 1.500 tokens · 3 $/1M = **15 $/mes ≈ 14 €/mes**
- Sentry: gratis (dev team)
- Uptime Robot: gratis
- **TOTAL rango: 6 - 18 €/mes · 72 - 216 €/año**
- Con buffer × 4 (picos imprevistos + errores): **35 - 85 €/mes · 420 - 1.020 €/año**

3.4 Escenario 1.000 MAU (SMS multi-servicio · 2027)

- Dominio: 1,25 €/mes
- Firebase:
- Reads 800k → 0 € (dentro free tier mensual: 50k/día × 30 = 1,5M/mes free)
- Writes 200k → 0 € (600k/mes free)
- Functions 5M invocaciones → (5M - 2M) × 0,40 $/M = 1,20 $ → **1,10 €/mes**
- Auth 1.000 MAU → 5,50 €/mes
- Storage 5 GiB → 0,90 €/mes
- Egress 20 GiB → 2,20 €/mes
- Backups 15 GiB/mes → 0,35 €/mes
- **Subtotal Firebase: ≈ 10 €/mes**
- IA (con SLA pagado · 36.000 llamadas/mes):
- Escenario híbrido económico: 36.000 · 1,9k tokens · 0,70 $/1M ≈ **48 $/mes ≈ 45 €/mes**
- Escenario premium: ≈ **180 €/mes**
- Escenario pesimista (usuarios muy activos, imagen pesada): ≈ **350 €/mes**
- Monitoring paid (Sentry Team Plus): 29 $/mes ≈ **27 €/mes** (opcional)
- **TOTAL rango: 90 - 240 €/mes · 1.080 - 2.880 €/año** (sin Sentry paid)
- Con buffer × 1,8: **180 - 420 €/mes · 2.160 - 5.040 €/año**
- Escenario pesimista con Sentry paid y provider premium: **650 €/mes**

4. Necesidades técnicas para 1.000 MAU

4.1 Obligatorias antes de cruzar 100 MAU

- [x] App Check enforce activo (ya) — protege el gasto IA de abuso.
- [x] Rate limit por IP en `askAi` (ya, 30/min).
- [x] Cuota diaria por usuario (ya, 50/día · 200 admin).
- [x] Cache hash 7d (ya) — ahorra repetitivos.
- [ ] **Migrar a plan Blaze** en Firebase (necesario para backups + superar tier).
- [ ] **Alerta presupuestaria GCP Billing** a 20 €/mes con thresholds 50/90/100/150%.
- [ ] **Cuenta Anthropic o Gemini pagada** (SLA exigible).
- [ ] **Seguro RC profesional + ciber** (400-900 €/año, deducible coste operativo).

4.2 Recomendadas antes de 500 MAU

- [ ] Uptime Robot activado (gratis).
- [ ] Presupuesto de pruebas de carga (herramienta k6 o Loader): 1 ejecución antes de onboarding masivo. Coste: 20 €/mes durante 1 mes.
- [ ] TTL activa en `aiRequests` y `scan_uploads` (ya · 180d / 365d).
- [ ] Segundo dev con acceso Write al repo + IAM editor (NDA firmado).
- [ ] Panel SLA público `/status.html` (ya desplegado).
- [ ] Presupuesto picos: provisionar el 50% encima del gasto típico.

4.3 Recomendadas antes de 1.000 MAU

- [ ] Multi-tenancy con colección `centros` + `centroId` propagado a todas las escrituras (ya implementado PR #71).
- [ ] Branding dinámico por tenant (ya implementado PR #74).
- [ ] Billing Dashboard nativo en admin (ya · dashboard cost/día).
- [ ] Export mensual PDF a cliente (ya · PR #78).
- [ ] FHIR R4 export para integración con HCE (ya añadido 2026-04-24).
- [ ] Escalado memoria `askAi` de 512 MiB a 1 GiB si se observan p95 > 5s.
- [ ] Posible paso a Cloud Run para Functions de alto uso (si supera 2M invocaciones/mes sostenido).

4.4 Nice-to-have escalado mayor

- [ ] CDN ante GitHub Pages (Cloudflare free) para reducir egress.
- [ ] Worker separado para jobs pesados (FHIR export batch, PDF masivo).
- [ ] Replica de Firestore en `eur3` multi-region si se exige DR < 15 min.

5. Pricing contractual · recordatorio

Del dossier comercial Urgencias HSL (`dossier-comercial.html`):

CONCEPTO	AÑO 1	RECURRENTE AÑO 2+
Licencia servicio (80 profesionales)	3.500 €	3.500 €
Mantenimiento evolutivo	2.400 €	2.400 €
Hosting + IA con SLA	1.200 €	1.200 €
Bolsa soporte 40 h (SLA 24 h)	2.000 €	2.000 €
Módulo específico *"Fármacos de Urgencia"*	2.500 €	—
Onboarding + 2 sesiones formación	1.200 €	—
Reporting trimestral	1.200 €	1.200 €
TOTAL año 1	**14.000 €** IVA excluido	
TOTAL recurrente año 2		**10.300 €** + módulo nuevo 2.500 €

Coste real operativo estimado (100 MAU · escenario medio 60 €/mes): **720 €/año**.

Margen operativo año 1: **13.280 €** (95%).

Margen operativo año 2 recurrente: **9.580 €** (93%).

Nota: el margen se usa para (a) seguro RC + ciber, (b) tiempo dev del autor + backup, (c) acreditaciones (HONcode, WIS, Web Sanitaria Acreditada), (d) reserva técnica para picos y crecimiento.

---

6. Alertas presupuestarias recomendadas

Comando gcloud (ejecutar en Cloud Shell cuando Blaze esté activo):

```
# Ver billing account
gcloud billing accounts list

# Crear budget con alertas
gcloud billing budgets create \
  --billing-account=BILLING_ID \
  --display-name="Cartagenaeste mensual" \
  --budget-amount=20EUR \
  --threshold-rule=percent=0.5 \
  --threshold-rule=percent=0.9 \
  --threshold-rule=percent=1.0 \
  --threshold-rule=percent=1.5 \
  --filter-projects=projects/docenciacartagenaeste
```

Escalar el budget cuando crezca usuario base:

MAU	BUDGET RECOMENDADO
0-50	20 €/mes
50-200	80 €/mes
200-500	200 €/mes
500-1.000	500 €/mes
>1.000	800 €/mes

7. Riesgos económicos

RIESGO	PROBABILIDAD	MITIGACIÓN
Proveedor IA sube precios 2×	Media	Cadena de fallback con 5 proveedores
Uso malicioso de la API (abuso)	Baja (App Check)	Rate limit + cuotas + alerta budget
Crecimiento repentino sin cobertura	Media	Budget alert + pausa temporal IA en cuota drenada
Caída de Firebase 24 h	Muy baja	Aceptable para sistema formativo · disclaimer
Cambio Google pricing Firebase	Alta (histórico)	Revisión semestral + posible migración parcial a Supabase/Cloudflare D1

8. Historial de revisiones

FECHA	CAMBIOS
2026-04-24	Documento inicial. Escenarios hoy / 100 / 1.000 MAU con rangos realistas.